Podstawy uczenia maszynowego

metody liniowe

ćwiczenia nr 1

Akademia Górniczo-Hutnicza
im. Stanisława Staszica w Krakowie
AGH University of Krakow

semestr letni 2025/2026

Paweł Szczerbiak

Czym się zajmiemy na ćwiczeniach?

Ćwiczenia 1: metody liniowe

Ćwiczenia 2: metody oparte na sąsiedztwie

Ćwiczenia 3: metody jądrowe

Ćwiczenia 4: metody probabilistyczne

Ćwiczenia 5: klasyfikacja niezbalansowana

Ćwiczenia 6: selekcja cech i redukcja wymiarowości

Ćwiczenia 7: klasteryzacja

Zagadnienia

1. Regresja w uczeniu maszynowym
2. Modele liniowe
   a. model addytywny
   b. model liniowy efektów mieszanych
   c. uogólniony model liniowy
   d. uogólniony model addytywny
3. Regularyzacja
   a. Lasso
   b. Grzbietowa (ridge)
   c. Elastic net
4. Regresja Hubera
5. Przetwarzanie wstępne
   a. imputacja danych
   b. one-hot encoding
   c. eliminacja silnej korelacji
   d. skalowanie cech

Regresja w uczeniu maszynowym

1. Paradygmat: **uczenie nadzorowane** (*supervised learning*)
2. Architektura: **dowolna**
3. Przewidujemy **zmienną zależną** za pomocą zmiennych niezależnych
4. Zmienna zależna jest zwykle **liczbą rzeczywistą**
5. Minimalizujemy błąd - różnicę między wartością rzeczywistą a predykcją: **MAE, MSE**
6. Zastosowania:
   a. modelowanie wzrostu populacji
   b. szacowanie ryzyka kredytowego
   c. ocena zużycia energii
   d. szacowanie kosztów transportu
   e. …i wiele, wiele innych

$$\mathrm{MAE} = \frac{1}{n}||y - \hat{y}||_1$$

$$\mathrm{MSE} = \frac{1}{n}||y - \hat{y}||_2^2$$

$$\mathrm{RMSE} = \sqrt{\mathrm{MSE}}$$

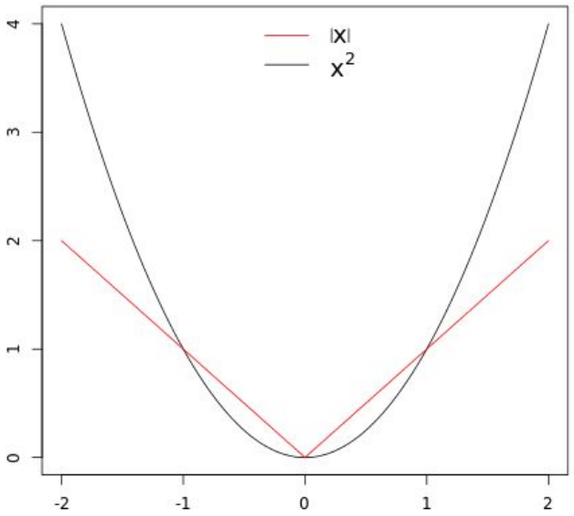

Konwencja: $||x|| \equiv ||x||_2$

thedatascientist.com

Modele liniowe - (klasyczny) model liniowy

$$Y = w_0 + \sum_{j=1}^{p} w_j X_j + \varepsilon$$

1. Najprostszy model liniowy (dobry jako *baseline*)
2. Szacujemy **średnią warunkową** (*conditional mean*)
3. Szukamy **wag** modelu
4. W tym celu rozwiązujemy problem analitycznie lub minimalizujemy funkcję kosztu
5. Wyraz wolny (*intercept*, *bias*) jest równy 1
6. Rozwiązanie analityczne (*normal equations*, *linear least squares*):

$$w = (X^T X)^{-1} X^T Y$$

Modele liniowe - model addytywny

$$Y = w_0 + \sum_{j=1}^{p} w_j f_j(X_j) + \varepsilon$$

1. Zastępujemy zwykłą zależność od wag dowolnymi **funkcjami regularnymi**
2. Do poszukiwania tych funkcji stosuje się algorytm dopasowania wstecznego
3. Bardziej elastyczny niż klasyczny model liniowy

Modele liniowe - model efektów mieszanych

$$Y = \sum_{j=1}^{p} w_j X_j + \sum_{j=1}^{m} u_j Z_j + \varepsilon$$

1. Zawiera zarówno **efekty stałe,** jak i efekty losowe
2. Przydatny, gdy dokonywane są **powtarzające się pomiary** na tych samych jednostkach statystycznych (*longitudinal studies*) lub gdy pomiary dokonywane są na grupach powiązanych jednostek statystycznych
3. Alternatywa dla analizy wariancji (ANOVA / ANCOVA) dla powtarzanych pomiarów
4. Dla zainteresowanych: omówienie

Modele liniowe - uogólniony model liniowy

$$\mathbb{E}[Y|X] = \mu = g^{-1}(w_0 + wX)$$

1. Pozwala, żeby *Y* mogła podlegać **dowolnemu rozkładowi** (zamiast ograniczać się do rozkładu normalnego)
2. Funkcja *g* zwyczajowo nazywa się **funkcją wiążącą** (*link function*)
3. Regresja logistyczna jest szczególnym przypadkiem, gdy *g* jest funkcją logitową (ćw. 4)
4. Przykład: regresja Poissonowska

Modele liniowe - uogólniony model addytywny

$$\mathbb{E}[Y|X] = \mu = g^{-1}\left(w_0 + \sum_{j=1}^{p} w_j f_j(X_j)\right)$$

1. **Połączenie** modelu addytywnego (AM) i uogólnionego modelu liniowego (GLM)
2. Motywacja pochodzi z twierdzenia Kołmogorowa-Arnolda, które mówi, że **każda funkcja wielowymiarowa może być przedstawiona jako suma i kompozycja funkcji jednowymiarowych** (przykład)
3. Dla uproszczenia, pomija się zewnętrzną sumę
4. Sieci neuronowe Kolmogorova-Arnolda (KAN)

Regularyzacja

1. Używana, żeby **powstrzymać model** przed nadmiernym przeuczeniem (*overfitting*)
2. Czasem wagi modelu są **zbyt duże** i niewielkie wahania *X* powodują dużą zmianę *Y*
3. Chcemy **zmniejszyć** wartości wag, czasem do zera

$$\min_f \sum_{i=1}^{n} V(f(x_i), y_i) + \lambda R(f)$$

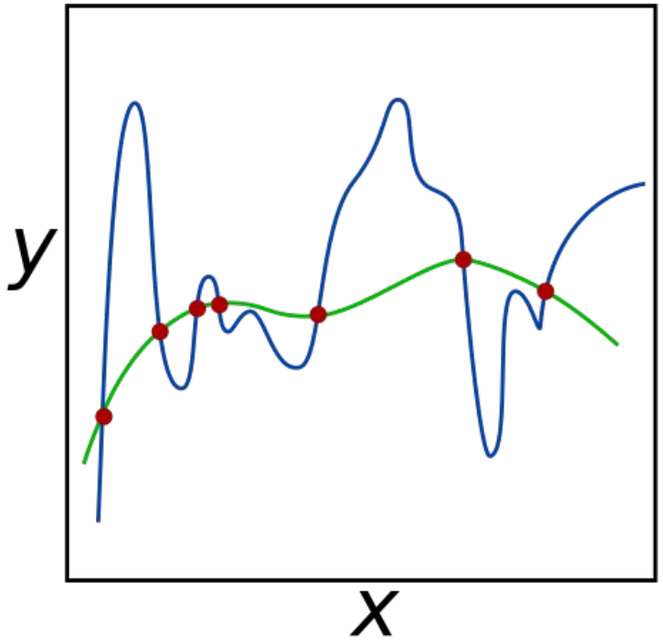

wikipedia.org

Regularyzacja - L1 oraz L2

1. Regularyzacja L1
   a. **Lasso** (*least absolute shrinkage and selection operator*)
   b. Nieróżniczkowalna, ale można użyć np. *coordinate descent* albo LARS
2. Regularyzacja L2
   a. Grzbietowa (ridge)
   b. Różniczkowalna,
   wydajny algorytm to np. SVD

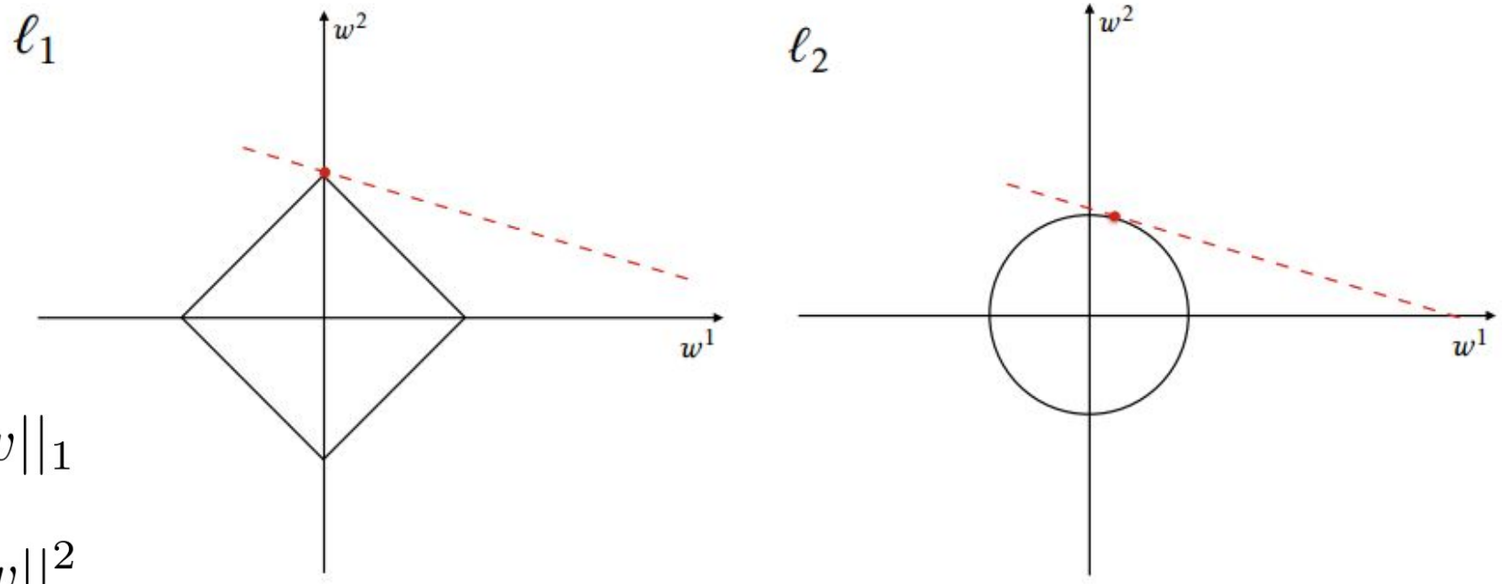

$$L_{LASSO}(w) = \frac{1}{n}||y - Xw||^2 + \lambda||w||_1$$

$$L_{ridge}(w) = \frac{1}{n}||y - Xw||^2 + \lambda||w||^2$$

wikipedia.org

Regularyzacja - L1 oraz L2

L1

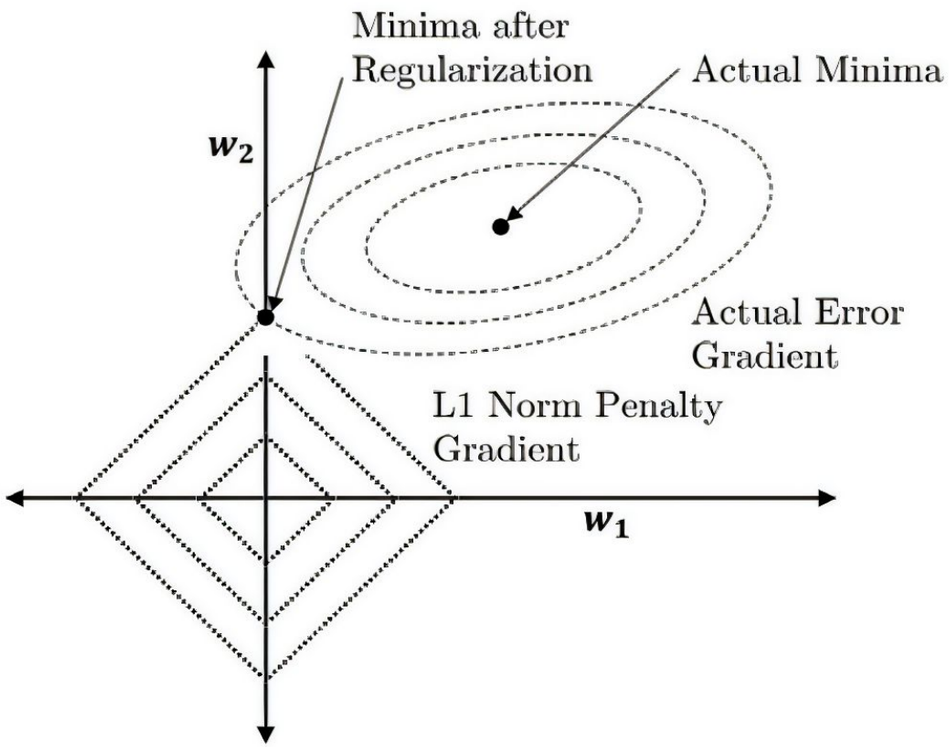

L2

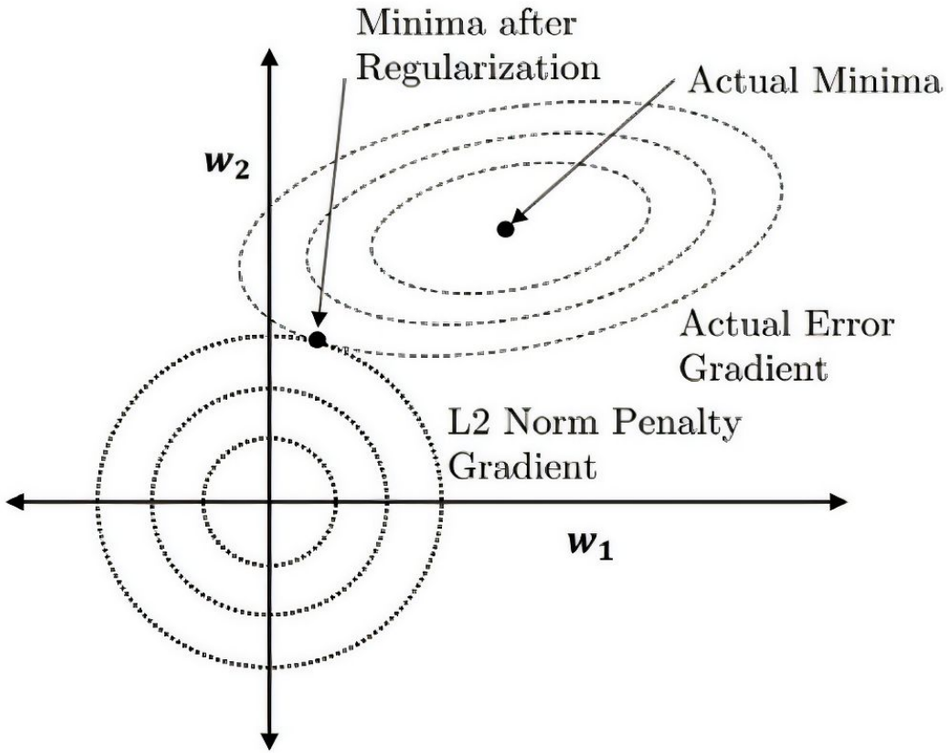

Towards Data Science

Regularyzacja - L1 + L2

1. Regularyzacja L1 + L2
   a. **Elastic net** (połączenie Lasso i Ridge)
   b. Optymalizacja jak Lasso
   c. Pozwala uniknąć problemu z Lasso dla “dużego *p* (liczba cech), małego *n* (liczba próbek)”
   d. Związek z maszynami wektorów nośnych (SVM)

$$L(w) = \frac{1}{N}||y - Xw||^2 + \lambda||w||_2^2 + \alpha||w||_1$$

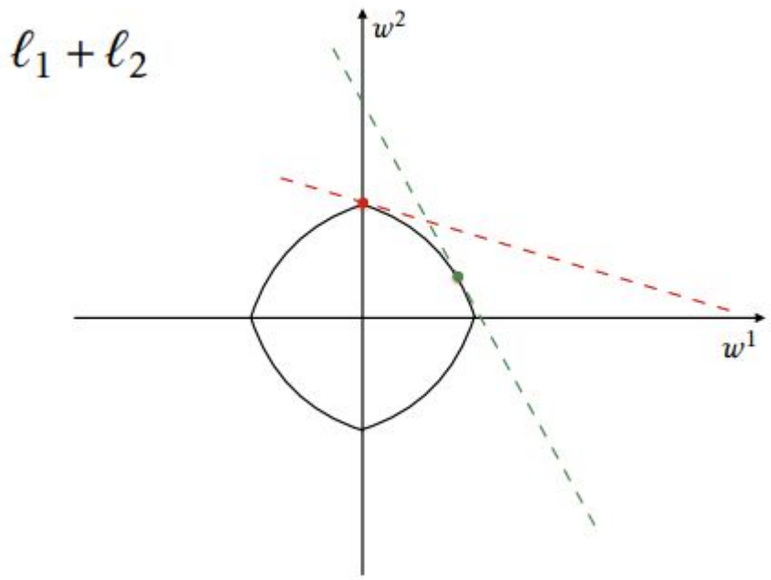

wikipedia.org

Regresja Hubera

1. Funkcja kosztu bazuje zarówno na **MSE** (blisko zera) jak i na **MAE** (dalej)
2. Łączy zalety obu tych funkcji kosztu
3. Bardziej odporna na punkty odstające (*outliers*) niż MSE
4. Do optymalizacji można użyć L-BFGS

$$L_{huber}(w) = \begin{cases} \frac{1}{2}||y - Xw||^2 & \text{for } |y - Xw| \leq \epsilon \\ \epsilon * (||y - Xw||_1 - \frac{1}{2}\epsilon) & \text{otherwise} \end{cases}$$

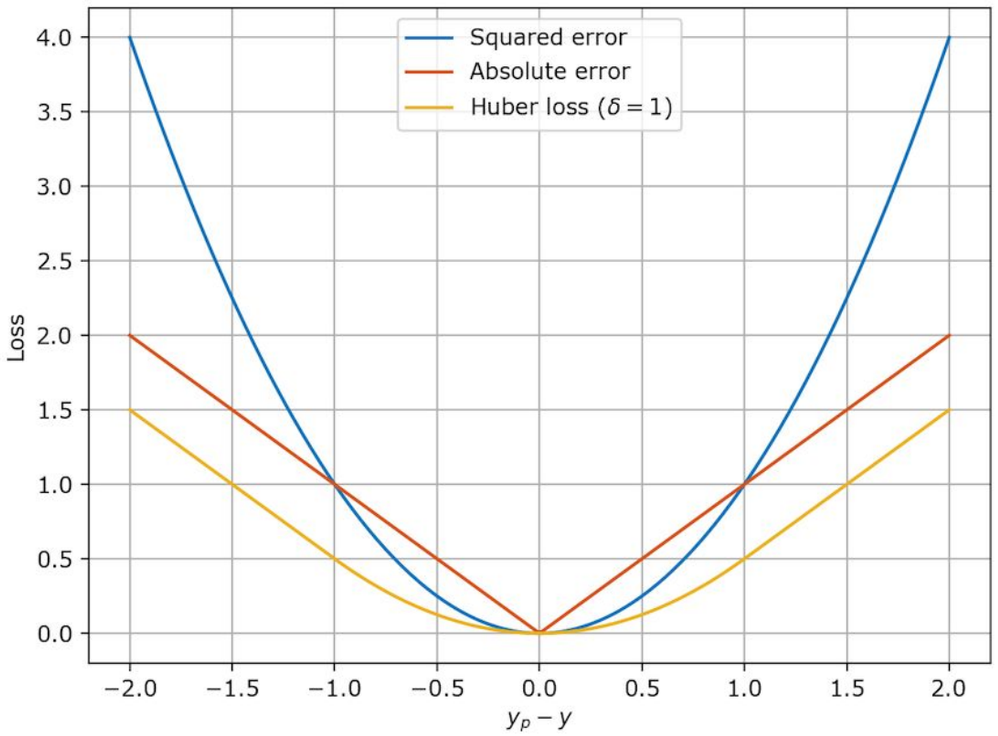

evergreeninnovations.co

Przetwarzanie wstępne - imputacja danych

1. Jeśli dane są niekompletne, mamy z reguły dwa wyjścia:
   a. usunąć całkowicie dany rekord (ale tracimy dane)
   b. “naprawić dane” (ale wprowadzamy obciążenie, *bias*)

Typ danych	Najczęstsza technika
numeryczny	Podstawienie: ● średnia arytmetyczna (*mean*) ● mediana (wartość środkowa, *median*) ● dominanta (wartość najczęstsza, *mode*) ● dana wartość (np. 0, etc.)
kategoryczny	● podstawienie najczęstszej kategorii ● dodatkowa kategoria

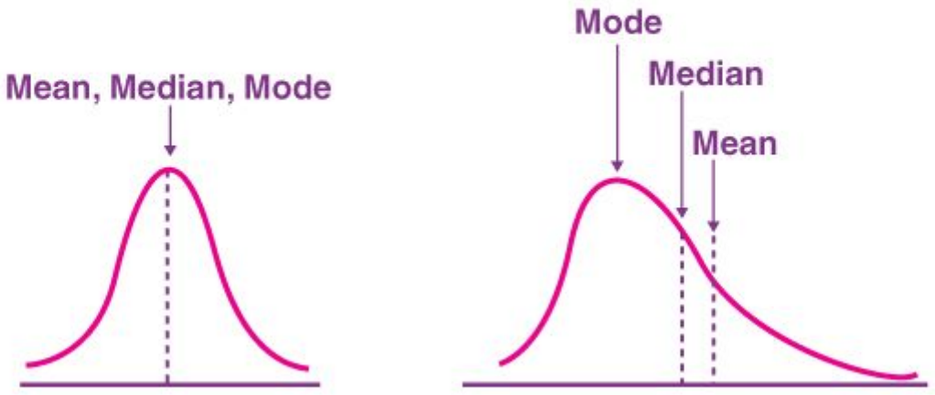

byjus.com

Przetwarzanie wstępne - one-hot encoding

1. W regresji żądamy, aby zmienne wyjaśniające *X* miały wartości numeryczne
2. Jeśli ***X* składa się z wartości kategorycznych**, należy zastosować *one-hot encoding*:
   a. każda kategoria kodowana jest za pomocą wektora o długości równej liczbie kategorii
   b. wektor ma same zera i jedną wartość 1 dla indeksu przypisanego danej kategorii
   c. usuwamy jedną kategorię, żeby uniknąć *dummy variable trap* (przykład)

Color
Red
Red
Yellow
Green
Yellow

Red	Yellow	Green
1	0	0
1	0	0
0	1	0
0	0	1

medium.com

Przetwarzanie wstępne - eliminacja silnej korelacji

1. Jeśli zmienne wyjaśniające ***X* są silnie skorelowane** (*multicollinearity*), może utrudnić to znalezienie optymalnego rozwiązania
2. W praktyce należy:
   a. wybrać po jednej cesze z każdego zbioru skorelowanych cech np. o największej wariancji (selekcja cech)
   b. zastosować regularyzację

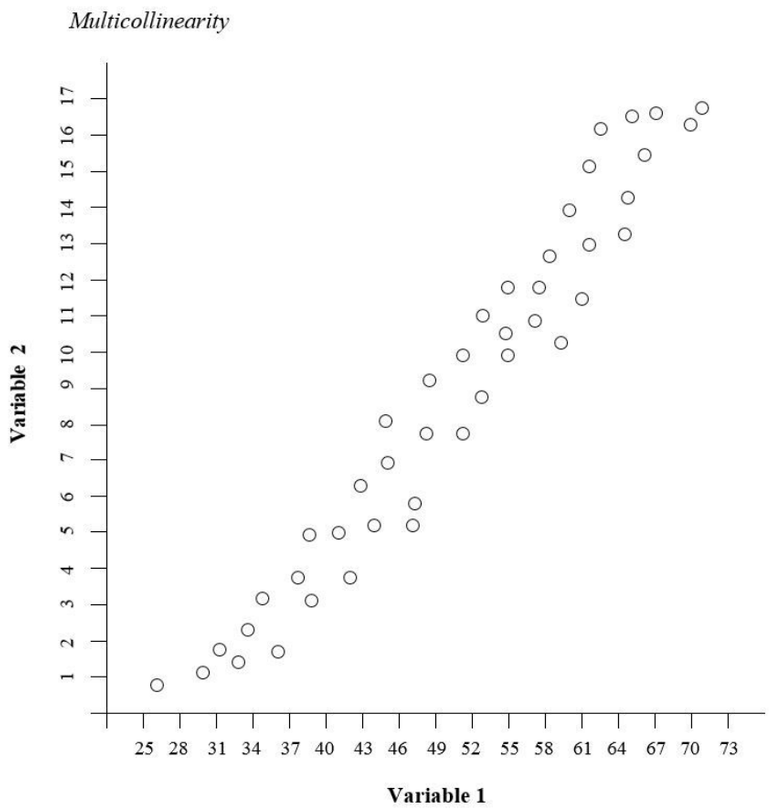

Note. The plot depicts the predictor variables, Variable 1 and Variable 2, as highly linearly related.

wikipedia.org

Przetwarzanie wstępne - skalowanie cech

1. W celu ułatwienia treningu modelu w uczeniu maszynowym, warto sprowadzić zmienne do podobnej skali
2. Dwie najprostsze techniki to:
   a. **normalizacja** (zakres [0, 1])
   b. **standardyzacja** (zerowa wartość oczekiwana i jednostkowa wariancja)

$$X_{\text{norm}} = \frac{X - X_{\min}}{X_{\max} - X_{\min}}$$

$$X_{\text{std}} = \frac{X - \mu}{\sigma}$$

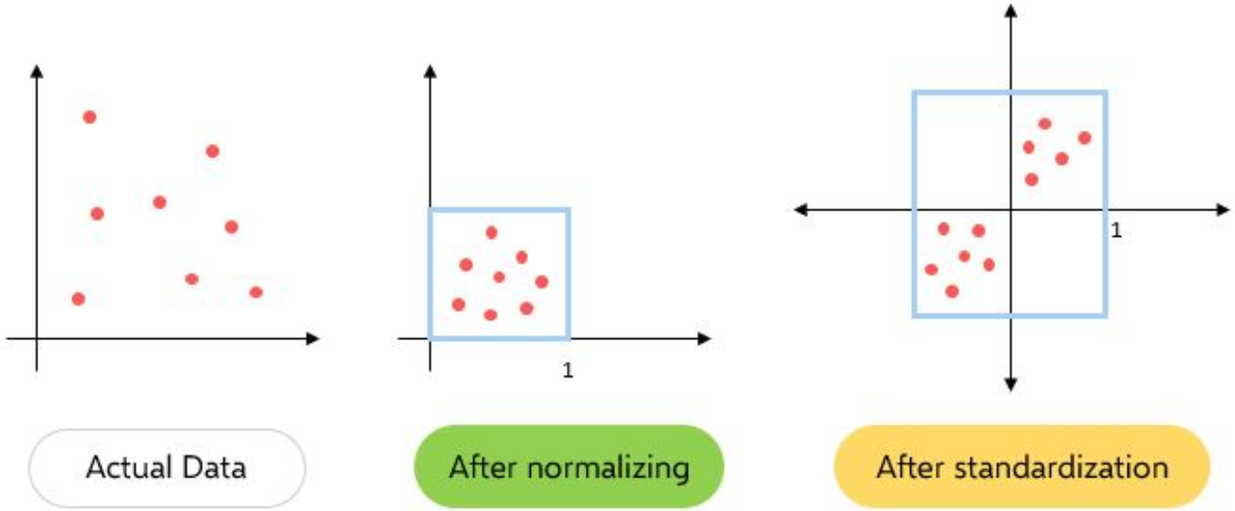

someka.net

Do zapamiętania

1. Czym jest regresja w uczeniu maszynowym
2. Rodzaje modeli liniowych
3. Rodzaje regularyzacji
   a. L1
   b. L2
   c. ich kombinacja
4. Rodzaje regresji
5. Wstępne przetwarzanie danych
   a. imputacja danych
   b. one-hot encoding
   c. eliminacja silnej korelacji
   d. skalowanie cech

Typ regresji	Funkcja kosztu
Liniowa	MSE, MAE
Lasso	MSE + regularyzacja L1
Grzbietowa (ridge)	MSE + regularyzacja L2
Elastic net	MSE + regularyzacja L1 i L2
Huber	Huber Loss (łącząca MSE i MAE)