Podstawy uczenia maszynowego

metody oparte na sąsiedztwie

ćwiczenia nr 2

Akademia Górniczo-Hutnicza
im. Stanisława Staszica w Krakowie
AGH University of Krakow

semestr letni 2025/2026

Paweł Szczerbiak

Czym się zajmiemy na ćwiczeniach?

Ćwiczenia 1: metody liniowe

Ćwiczenia 2: metody oparte na sąsiedztwie

Ćwiczenia 3: metody jądrowe

Ćwiczenia 4: metody probabilistyczne

Ćwiczenia 5: klasyfikacja niezbalansowana

Ćwiczenia 6: selekcja cech i redukcja wymiarowości

Ćwiczenia 7: klasteryzacja

Zagadnienia

1. Klasyfikacja w uczeniu maszynowym
2. Metody najbliższych sąsiadów
3. Klasyfikator k najbliższych sąsiadów (kNN)
4. Regresja k najbliższych sąsiadów
5. Hiperparametry
6. Metryki odległości
   a. definicja metryki
   b. podstawowe metryki
7. Klątwa wymiarowości

Klasyfikacja w uczeniu maszynowym

1. Paradygmat: **uczenie nadzorowane** (*supervised learning*)
2. Architektura: **dowolna**
3. Przewidujemy **jedną lub wiele klas** na podstawie danych wejściowych
4. Dane wejściowe mogą być dowolnego typu
5. Minimalizujemy błąd **- bardzo szeroki wybór funkcji kosztu**
6. Zastosowania:
    a. rozpoznawanie obiektów
    b. wykrywanie chorób
    c. systemy rekomendacyjne
    d. wykrywanie oszustw
    e. …i wiele, wiele innych

Metoda najbliższych sąsiadów

1. Zakładamy, że punkty leżące **blisko siebie** w przestrzeni mają podobne właściwości
2. Dość odporna na punkty odstające (*outliers*), gdyż działa na zasadzie **interpolacji**
3. **Duży koszt obliczeniowy.** Rozwiązania: *k-d trees*, *approximate nearest neighbors*
4. Bardzo dobra metoda jako ***baseline***
5. Wybór k:
   a. małe k: duża wariancja, małe obciążenie (*bias*)
   b. duże k: mała wariancja, duże obciążenie (*bias*)
6. Zastosowania:
   a. klasyfikacja (np. kNN)
   b. regresja (np. *nearest neighbors regression*)
   c. wyszukiwanie (np. *semantic search*)
   d. systemy rekomendacyjne

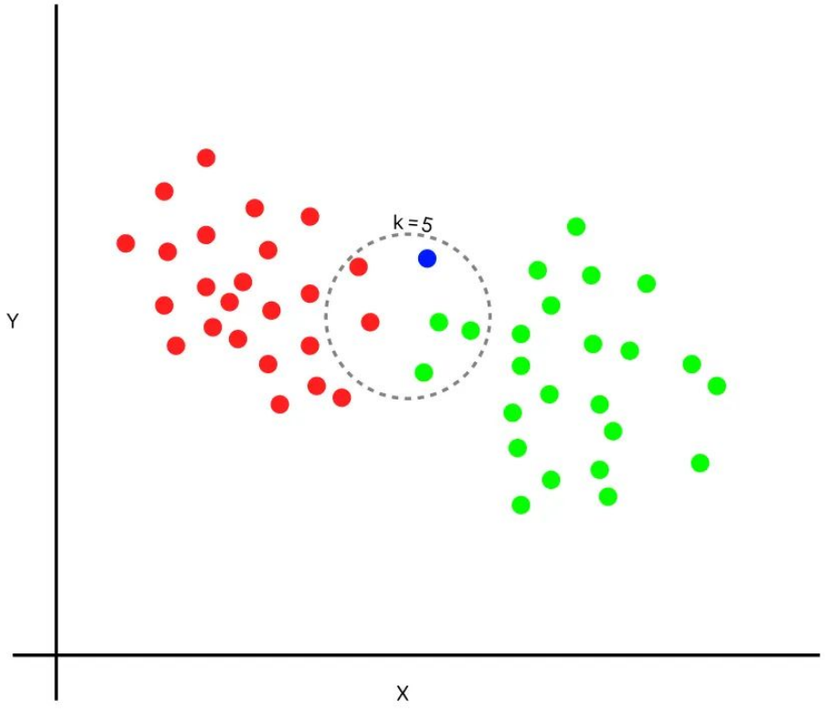

pub.towardsai.net

Klasyfikator k najbliższych sąsiadów (kNN)

1. Wybierz liczbę sąsiadów (k)
2. Dla nowego punktu danych oblicz odległość między tym punktem a wszystkimi punktami w zestawie treningowym
3. Zidentyfikuj k punktów w zestawie treningowym, które znajdują się najbliżej nowego punktu danych
4. Oblicz **prawdopodobieństwo** przynależności do klas k sąsiednich punktów i zwróć najbardziej popularną klasę

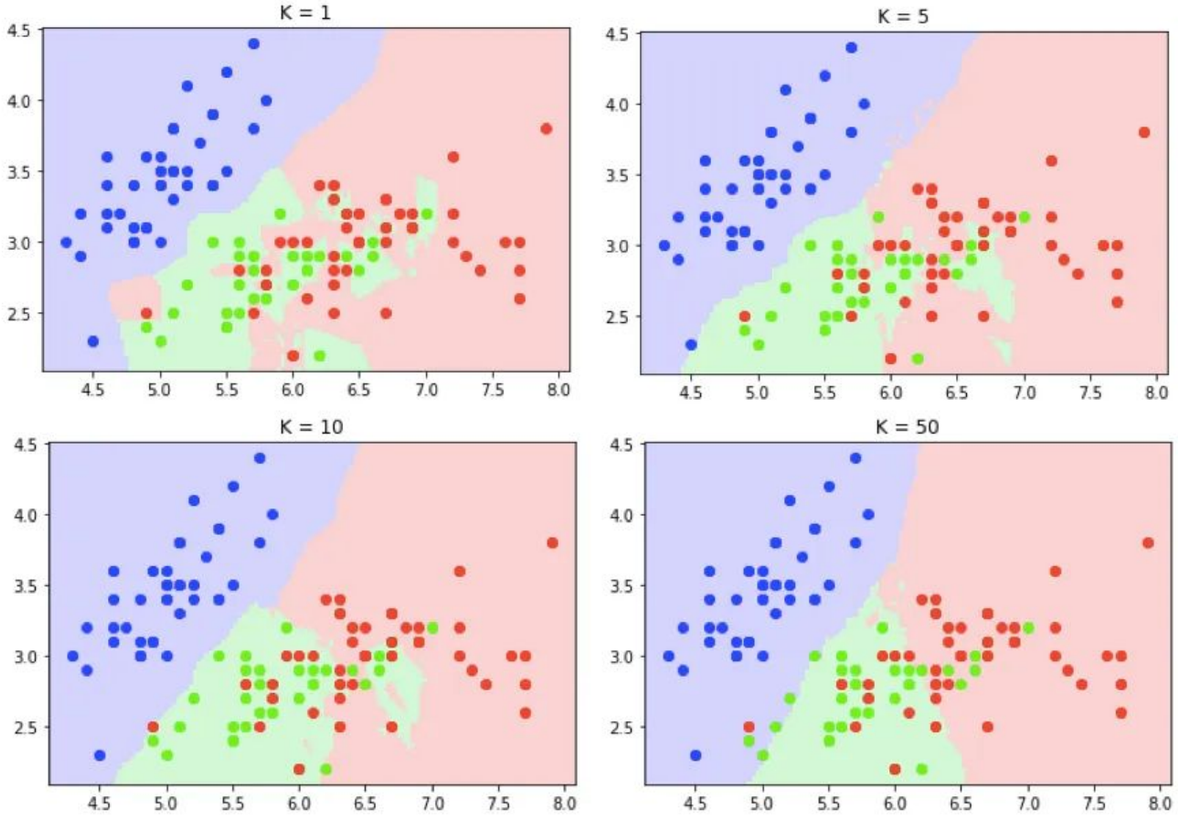

medium.com

Regresja k najbliższych sąsiadów

1. Wybierz liczbę sąsiadów (k)
2. Dla nowego punktu danych oblicz odległość między tym punktem a wszystkimi punktami w zestawie treningowym
3. Zidentyfikuj k punktów w zestawie treningowym, które znajdują się najbliżej nowego punktu danych
4. **Oblicz średnią wartość k najbliższych sąsiadów** i użyj jej jako wartości przewidywanej dla nowego punktu danych

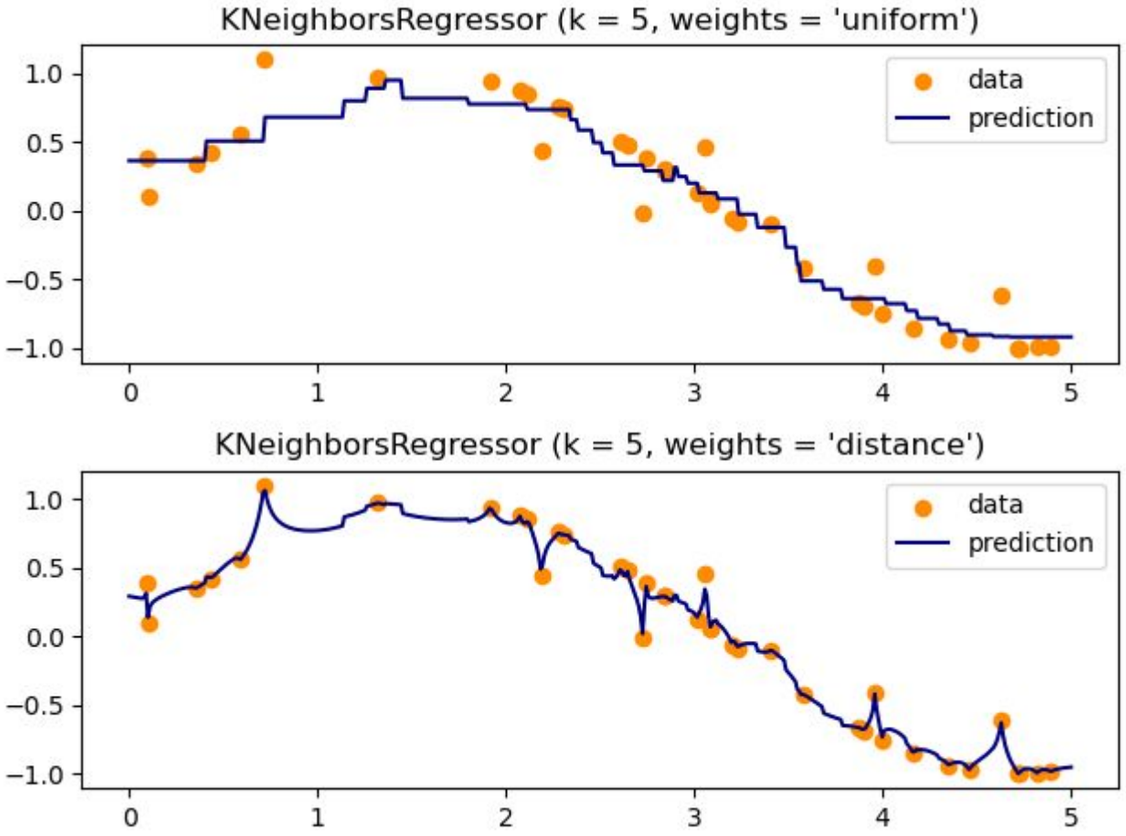

scikit-learn.org

Hiperparametry

1. **Liczba k**
   a. najistotniejszy hiperparametr
   b. wpływa na *bias-variance trade-off*
2. **Ważenie sąsiadów**
   a. może poprawić wyniki
   b. najprostsza implementacja: 1 / odległość
3. **Metryki odległości**
   a. domyślnie to metryka Euklidesowa
   b. wpływ rośnie wraz z liczbą wymiarów
   c. szerzej w kolejnej sekcji…

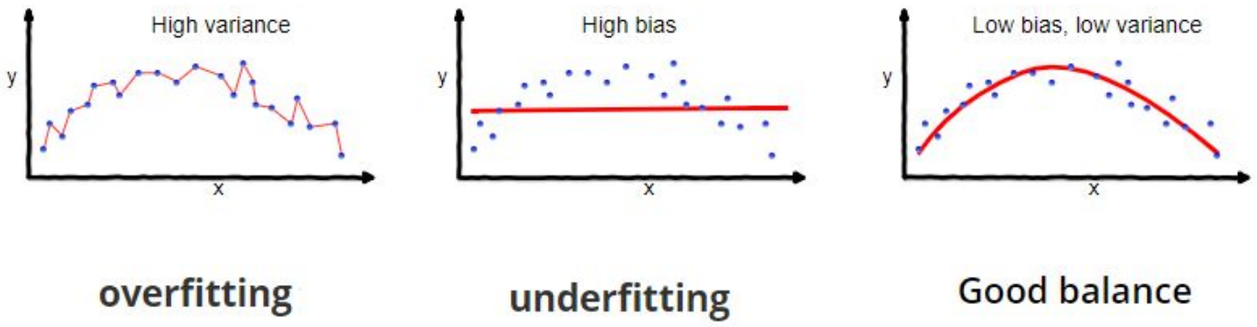

Uwaga: model nie podlega treningowi - parametry są *implicite* zawarte w danych treningowych (*lazy learning*, *instance-based learning*) - por. maszyna wektorów nośnych (ćw. 3)

towardsdatascience.com

Mierzenie odległości - definicja metryki

1. Funkcja postaci: $d : M \times M \to \mathbb{R}$ że dla każdego $x, y, z \in M$ zachodzą poniższe aksjomaty:
   a. zerowa odległość do samego siebie: $d(x, x) = 0$
   b. dodatniość: $x \neq y \implies d(x, y) > 0$
   c. symetria: $d(x, y) = d(y, x)$
   d. nierówność trójkąta: $d(x, z) \leq d(x, y) + d(y, z)$
2. Traktuje wszystkie zmienne tak samo, a zatem:
   a. wymaga **przeskalowania** wszystkich zmiennych

Mierzenie odległości - podstawowe metryki

Metryki indukowane *p*-normami:

1. Metryka Manhattan (L1):

   (albo: *city block*)

$$d_1(x,y) = \sum_{i=1}^{N} |x_i - y_i|$$

2. Metryka Euklidesowa:

$$d_2(x,y) = \sqrt{\sum_{i=1}^{N} (x_i - y_i)^2}$$

3. Metryka supremum:

   (albo: Czebyszewa)

$$d_\infty(x,y) = \max_{i=1\ldots N} \{|x_i - y_i|\}$$

koło nie jest kołem!

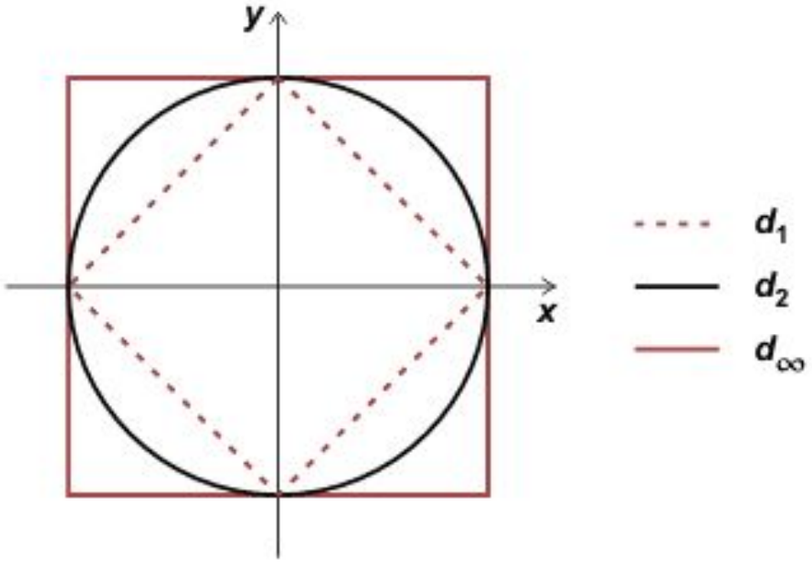

Konwencja: $||x|| \equiv ||x||_2$

Uwaga: *p* może być **ułamkowe.** Co się dzieje dla p = ⅔?

h2g2.com

Mierzenie odległości - miary podobieństwa

1. Podobieństwo Hamminga:

   (np. dane tekstowe)

   proporcja elementów w dwóch wektorach, które są sobie równe na tych samych pozycjach

2. Podobieństwo Jaccarda:

   (np. porównanie zbiorów, dane binarne)

$$J(A,B) = \frac{|A \cap B|}{|A \cup B|} = \frac{|A \cap B|}{|A| + |B| - |A \cap B|}$$

3. Podobieństwo cosinusowe:

   (np. wektory rzadkie)

$$C(x,y) = \frac{x \cdot y}{||x||||y||}$$

$$d_2(x,y) = \sqrt{(x-y)\cdot(x-y)} = \sqrt{2(1 - C(x,y))}$$

$$\text{dla} \quad ||x|| = ||y|| = 1$$

- **Podobieństwo** (*similarity*) z reguły jest **znormalizowane** między [0, 1] albo [-1, 1]
- Mając podobieństwo, **możemy zdefiniować dystans**

Klątwa wymiarowości

Zestaw problemów w kombinatoryce, próbkowaniu, optymalizacji i uczeniu maszynowym **związanych ze wzrostem liczby wymiarów:**

1. **wymiar rośnie liniowo a objętość wykładniczo** z liczbą wymiarów (p)
2. podobieństwo między wektorami staje się coraz większe ze wzrostem wymiarów
3. im więcej wymiarów tym więcej danych treningowych (z reguły: $p \sim C\,n$, $C > 1$)

Rozwiązania:

1. inna metryka niż Euklidesowa
2. selekcja cech
3. mniejszy model dla małych zbiorów

5 obszarów
20% punktów

25 obszarów
4% punktów

125 obszarów
0.8% punktów

mamy 100 punktów do dyspozycji

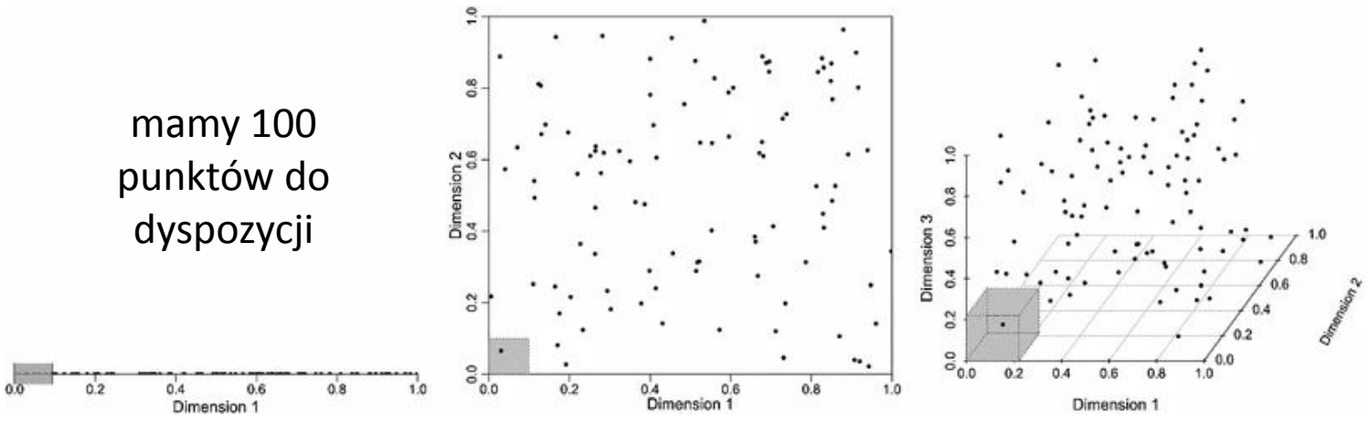

próbkujemy coraz mniej!

https://doi.org/10.1007/s10044-017-0649-0

Do zapamiętania

1. Czym jest klasyfikacja w uczeniu maszynowym
2. Idea metody najbliższych sąsiadów
3. Algorytm klasyfikatora kNN
4. Hiperparametry i “parametry” klasyfikatora kNN
5. Aksjomaty metryki
6. Podstawowe metryki i miary podobieństwa
7. Klątwa wymiarowości