Podstawy uczenia maszynowego

metody probabilistyczne

ćwiczenia nr 4

Akademia Górniczo-Hutnicza
im. Stanisława Staszica w Krakowie
AGH University of Krakow

semestr letni 2025/2026

Paweł Szczerbiak

Czym się zajmiemy na ćwiczeniach?

Ćwiczenia 1: metody liniowe

Ćwiczenia 2: metody oparte na sąsiedztwie

Ćwiczenia 3: metody jądrowe

Ćwiczenia 4: metody probabilistyczne

Ćwiczenia 5: klasyfikacja niezbalansowana

Ćwiczenia 6: selekcja cech i redukcja wymiarowości

Ćwiczenia 7: klasteryzacja

Zagadnienia

1. Regresja logistyczna (*logistic regression*)
2. Metoda największej wiarygodności (MLE)
3. Entropia krzyżowa (*cross-entropy*)
4. Twierdzenie Bayesa (*Bayes' theorem*)
5. Naiwny klasyfikator Bayesa (*naive Bayes classifier*)
6. Maksymalne szacowanie a posteriori (MAP)
7. Jądrowy estymator gęstości (KDE)
8. Elastyczny klasyfikator Bayesa
9. Modele deskryptywne i generatywne
10. Podsumowanie klasyfikatorów

Oznaczenia / uwagi:

- n - liczba danych treningowych
- p - liczba cech w wektorze
- K - liczba klas

- Dane to pary: (x_i, y_i) $i = 1 \ldots n$
- Każdy wektor x_i ma długość p
- Wartość y_i to jedna z kategorii $1 \ldots K$

- Domyślnie indeks i oznacza punkt treningowy

Regresja logistyczna (*logistic regression*)

1. Jeden z najpopularniejszych **klasyfikatorów** (wbrew swojej nazwie)
2. Często używany **jako ostatnia warstwa sieci** neuronowej
3. Domyślnie działa jako klasyfikator **binarny**
4. Modeluje **prawdopodobieństwo**
5. Można ją rozumieć jako **modyfikację regresji liniowej** (uogólniony model liniowy, ćw. 1):

$$\text{logit } p(x_i) = \log\left(\frac{p(x_i)}{1-p(x_i)}\right) = \beta^T x_i$$

p(x) symuluje $y_i = 1$

6. …albo rozwiązania równania logistycznego, co również prowadzi do funkcji sigmoidalnej:

$$\frac{d}{dx}p(x) = p(x)(1-p(x)) \overset{x\to\beta^T x_i}{\Longrightarrow} p(x_i) = \frac{e^{\beta^T x_i}}{e^{\beta^T x_i}+1} = \frac{1}{1+e^{-\beta^T x_i}}$$

[prawdopodobieństwo klasy 1]

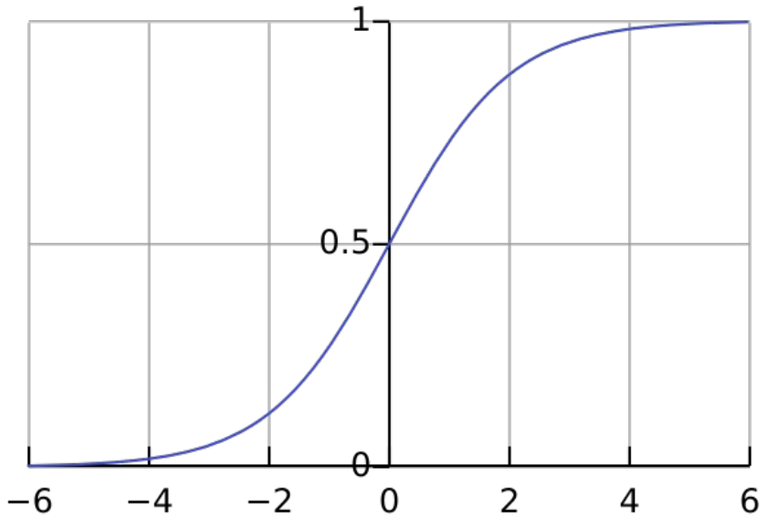

wikipedia.org

Metoda największej wiarygodności (MLE)

1. Ponieważ **przewidujemy prawdopodobieństwo**, stosujemy estymator największej wiarygodności (*maximum likelihood estimation*)
2. Interesuje nas maksymalizacja funkcji:

$$\tilde{L} = \prod_{\substack{i=1 \\ y_i=1}}^{n} p(x_i) \prod_{\substack{k=1 \\ y_k=0}}^{n} (1 - p(x_k)) = \prod_{i=1}^{n} p(x_i)^{y_i} (1 - p(x_i))^{1-y_i}$$

3. Rozważamy **ujemny logarytm** (zalety: stabilniejszy numerycznie, dokonujemy minimalizacji):

$$L = -\log \tilde{L} = \cdots = -\sum_{i=1}^{n} y_i \log p(x_i) - \sum_{i=1}^{n} (1 - y_i)(1 - p(x_i))$$

[**funkcja kosztu**, *cost function*]

4. Prowadzi to do **binarnej entropii krzyżowej**. Dla jednego punktu:

$$l_i = -y_i \log p_i - (1 - y_i) \log(1 - p_i)$$

[**funkcja straty**, *loss function*]

Binarna entropia krzyżowa (*binary cross-entropy*)

$$l_i = -y_i \log p_i - (1 - y_i) \log(1 - p_i)$$

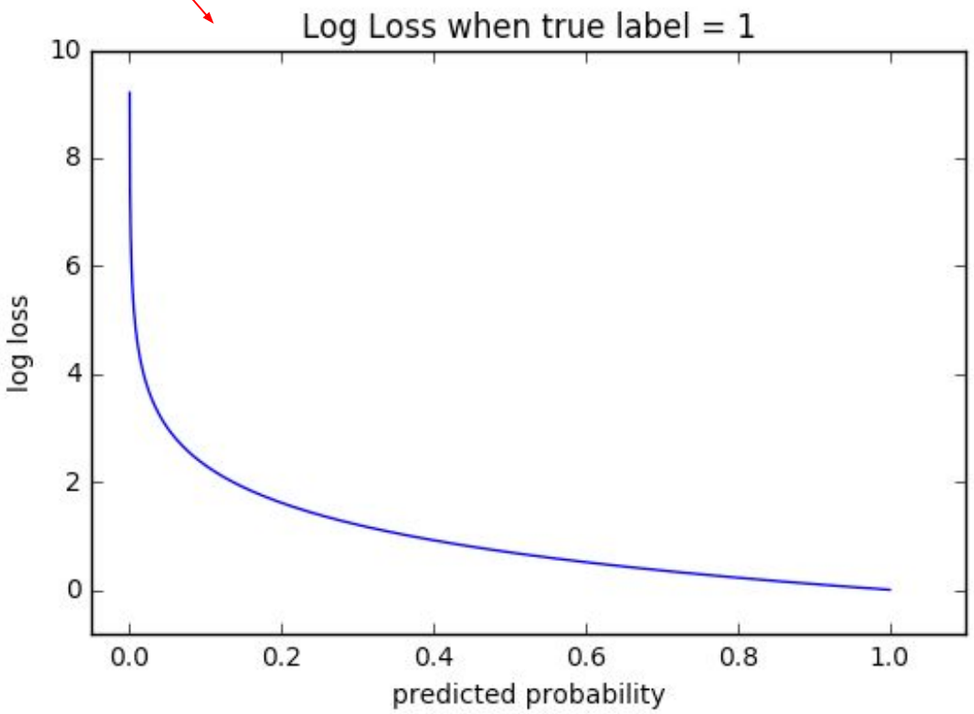

[prawdopodobieństwo klasyfikacji]

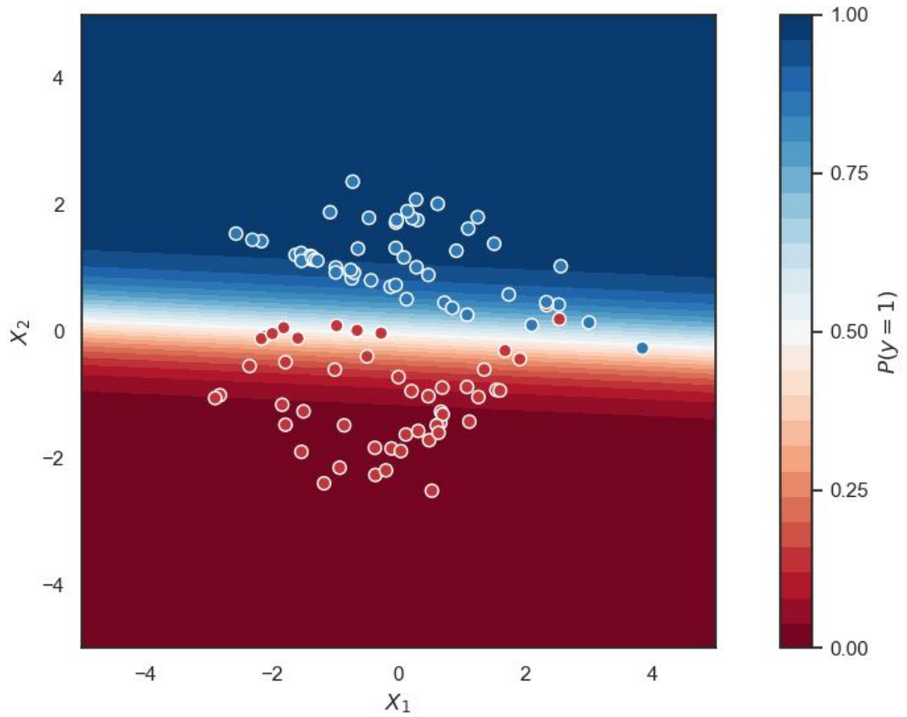

ml-cheatsheet.readthedocs.io
ml-explained.com

Kategoryczna entropia krzyżowa

1. Możemy uogólnić binarną entropii krzyżową na *K* klas (*categorical cross-entropy*):

$$l_{ik} = -\sum_{k=1}^{K} y_k \log p_k$$

2. W obu przypadkach można użyć **dowolnej regularyzacji** (L1, L2, L1+L2)
3. Formalnie, jest to **miara nietrafności** między dwoma rozkładami prawdopodobieństwa (w bitach)
4. Można ją wyrazić jako sumę nietrafności związanej z niepewnością p_{true} oraz rozbieżności Kullbacka-Leiblera między oboma rozkładami:

$$H(p_{\text{true}}, p) = -\mathbb{E}_{\text{true}}[\log p] = H(p_{\text{true}}) + d_{KL}(p_{\text{true}}, p)$$

[β ma wymiar p x K]

5. Gdy chcemy przewidywać *K* klas (*multi-class*), mamy dwa wyjścia:
   a. Softmax regression: entropia krzyżowa + funkcja softmax:
   b. trenowanie *K* modeli (*One-vs-Rest*, OvR)

$$p_{ik} = \frac{\exp(\beta_k^T x_i)}{\sum_{j=1}^{K} \exp(\beta_j^T x_i)}$$

Twierdzenie Bayesa (*Bayes' theorem*)

1. Zapis ogólny: $$\text{posterior} = \frac{\text{prior} \times \text{likelihood}}{\text{evidence}}$$ $$P(y|x) = \frac{P(y)P(x|y)}{P(x)}$$

2. Tabela podsumowująca:

Element	Nazwa polska	Nazwa angielska	Opis
P(y)	Prawd. a priori	*prior*	Prawdopodobieństwo klasy *y* (szacowane)
P(x|y)	Wiarygodność	*likelihood*	Prawdopodobieństwo otrzymania danych *x*, przy założeniu klasy *y*
P(x)	Dowód	*evidence*	Prawdopodobieństwo wystąpienia danych x (szacowane)
P(y|x)	Prawd. a posteriori	*posterior*	Prawdopodobieństwo klasy *y*, przy wystąpieniu danych *x*

Naiwny klasyfikator Bayesa

1. W praktyce, modelowanie wszystkich możliwych wartości $P(x|y)$ jest niewykonalne:
   a. za mało danych (estymacja obarczona zbyt dużym błędem)
   b. zbyt skomplikowane obliczeniowo (w ogólności rozkład p-wymiarowy, p - liczba cech)
2. Rozważymy **najprostszy** model (*naive Bayes classifier*):
   a. zakładamy, że cechy są warunkowo niezależne w obrębie każdej klasy (**nierealne**)
   b. pozwala to rozłożyć p-wymiarowy rozkład na iloczyn (p-1)-wymiarowych rozkładów
3. Do trenowania (a raczej fitowania) używamy MLE, a do przewidywania - MAP
4. Działa dobrze dla $p >> n$ (tzn. jest **odporny na klątwę wymiarowości**)
5. Zastosowania:
   a. prosty, interpretowalny *baseline*
   b. klasyfikacja tekstów
   c. filtrowanie spamu

Naiwny klasyfikator Bayesa - wyprowadzenie

1. Chcemy obliczyć:

$$P(y|x_1,\ldots,x_p) = \frac{P(y)P(x_1,\ldots,x_p|y)}{P(x_1,\ldots,x_p)}$$

2. Zakładamy niezależność cech:

$$P(x_i|y,x_1,\ldots,x_{i-1},x_{i+1},\ldots,x_p) = P(x_i|y)$$

3. Podstawiamy do pkt. 1:

$$P(y|x_1,\ldots,x_p) = \frac{P(y)\prod_{i=1}^{p} P(x_i|y)}{P(x_1,\ldots,x_p)}$$

4. Mianownik jest stały dla danego inputu:

$$P(y|x_1,\ldots,x_p) \propto P(y)\prod_{i=1}^{p} P(x_i|y)$$

5. Szacujemy przewidywanie za pomocą MAP:

$$\hat{y} = \arg\max_y P(y)\prod_{i=1}^{p} P(x_i|y)$$

6. Numerycznie używamy `LogSumExp`:

$$\hat{y} = \arg\max_y \exp\left(\log P(y) + \sum_{i=1}^{p} \log P(x_i|y)\right)$$

Naiwny klasyfikator Bayesa - podstawowe rodzaje

1. Prawdopodobieństwo $P(y)$ liczymy z rozkładu klas w danych treningowych
2. Różne naiwne klasyfikatory Bayesa różnią się założeniem na temat $P(x_i \mid y)$.

   Poniżej rozważamy wektory cech o długości p:

   - Bernoulliego

     $$P(x_i \mid y) = P(x_i = 1 \mid y)x_i + (1 - P(x_i = 1 \mid y))(1 - x_i)$$

     jawnie modeluje brak cechy

     - dane binarne np. `[0, 1, 0, ...]`
     - separacja liniowa
   - Wielomianowy (*multimodal*)

     estymatory MLE: $$\hat{\theta}_{yi} = \frac{N_{yi} + \alpha}{N_y + p\alpha}$$ parametr wygładzania

     - dane całkowite np. `[0, 11, 4, ...]`
     - separacja liniowa
   - Gaussowski

     $$P(x_i \mid y) = \frac{1}{\sqrt{2\pi\sigma_y^2}} \exp\left(-\frac{(x_i - \mu_y)^2}{2\sigma_y^2}\right)$$

     σ_y, μ_y szacowane za pomocą MLE

     - dane rzeczywiste np. `[-33.5, 2.3, 0.12, ...]`
     - separacja nieliniowa

MLP vs MAP

1. Obie metody dotyczą **szacowania punktowego** rozkładu prawdopodobieństwa **za pomocą dominanty** (*mode*)
2. Metoda największej wiarygodności (*maximum likelihood estimation*, MLE):

$$\hat{\theta}(x) = \underset{\theta \in \Theta}{\operatorname{argmax}}\, P(x|\theta)$$

3. Maksymalne szacowanie a posteriori (*maximum a posteriori*, MAP):

$$\hat{\theta}(x) = \underset{\theta \in \Theta}{\operatorname{argmax}}\, P(\theta|x) = \underset{\theta \in \Theta}{\operatorname{argmax}} \frac{P(x|\theta)P(\theta)}{\int_\Theta P(x|\vartheta)P(\vartheta)d\vartheta} = \underset{\theta \in \Theta}{\operatorname{argmax}}\, P(x|\theta)P(\theta)$$

4. **MLE** używa tylko **wiarygodności**, a **MAP** - zarówno **wiarygodności** jak **i prawd. a priori**
5. A zatem są równoważne dla równomiernego prawdopodobieństwa a priori
6. Obie **nie są reprezentatywne** dla wnioskowania Bayesowskiego

Jądrowy estymator gęstości (KDE)

1. *Kernel density estimation*
2. Przybliżamy dane (histogram) za pomocą **empirycznego** rozkładu prawdopodobieństwa (wygładzony histogram)
3. Jądro jest tu rozumiane jako **nieujemna funkcja jednej zmiennej** (por. ćw. 3):

$$\widehat{f}_h(x) = \frac{1}{n}\sum_{i=1}^{n} K_h(x - x_i) = \frac{1}{nh}\sum_{i=1}^{n} K\left(\frac{x - x_i}{h}\right)$$

[*h* to parametr wygładzania, *bandwidth*]
[suma po próbkach tj. danych]

4. **Przykład:** estymacja funkcjami Gaussowskimi:

$$\widehat{f}_h(x) = \frac{1}{nh\sigma}\frac{1}{\sqrt{2\pi}}\sum_{i=1}^{n} \exp\left(\frac{-(x - x_i)^2}{2h^2\sigma^2}\right)$$

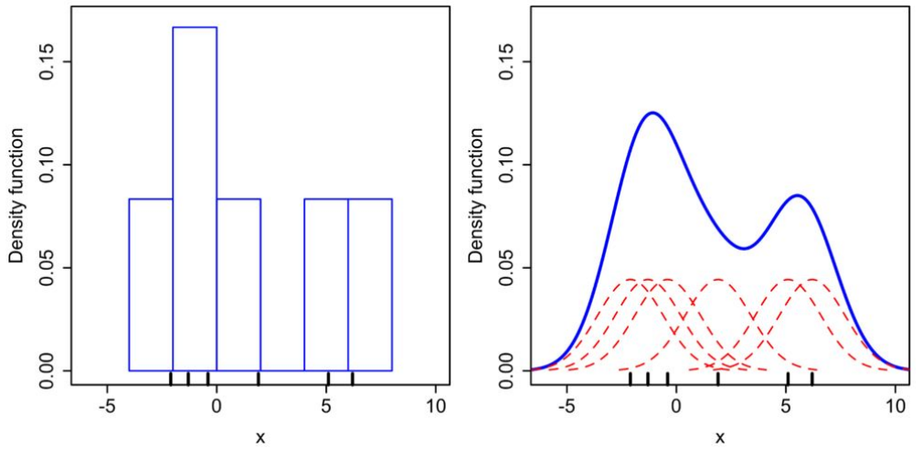

wikipedia.org

Elastyczny klasyfikator Bayesa

1. W przypadku **naiwnego klasyfikatora Bayesa** możemy użyć KDE do estymacji rozkładów brzegowych cech zależnych od klas (*class-conditional marginal densities*) tj. $P(x_i \mid y)$
2. Dotyczy to tylko cech ciągłych
3. Zastępujemy zwykły (globalny) rozkład Gaussa, rozkładem zależnym od danych
4. W literaturze klasyfikator taki nazywa się flexible Bayes classifier
5. Daje **lepsze wyniki**, ale jest **bardziej złożony obliczeniowo**

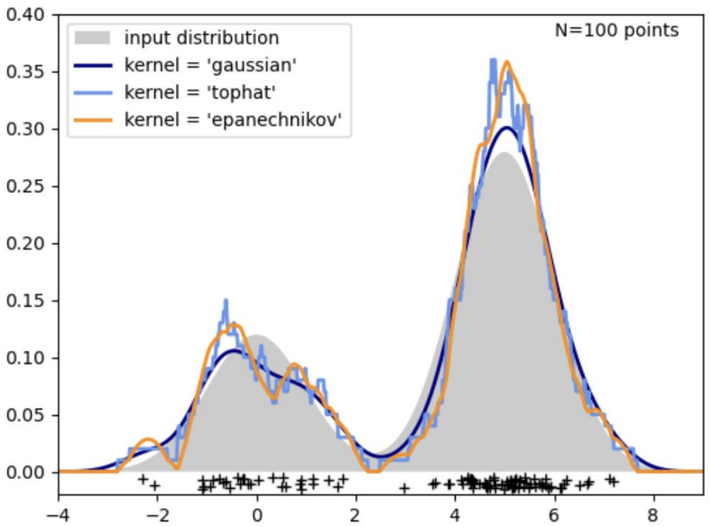

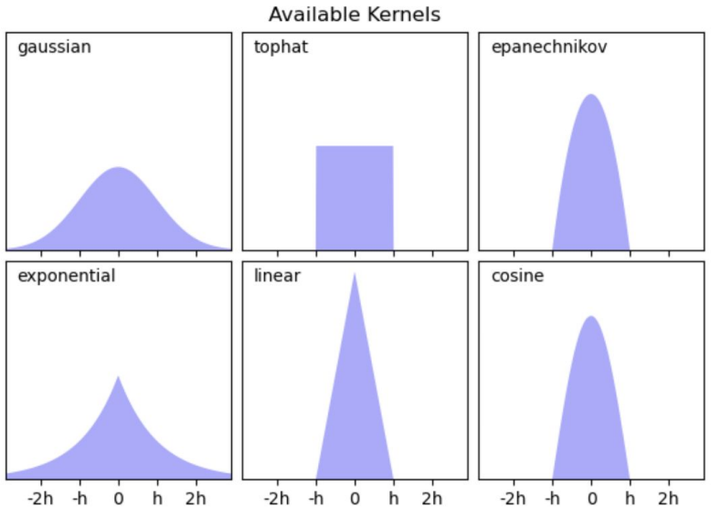

scikit-learn.org

Modele deskryptywne i generatywne

1. **Modele deskryptywne** (warunkowe) modelują prawdopodobieństwo **warunkowe** $P(y \mid x)$:
   a. jawnie poprzez MLE jak w regresji logistycznej
   b. niejawnie jak w maszynie wektorów nośnych (SVM) - nie ma tam pojęcia prawdopodobieństwa
   c. **zapamiętują** dane treningowe
   d. sztywne oddzielenie klas od siebie
2. **Modele generatywne** modelują wspólne (*joint*) prawdopodobieństwo $P(x, y)$:
   a. przykład: naiwny klasyfikator Bayesa
   b. uczą się procesu, w jakim dane mogły być wygenerowane
   c. dzięki temu mają cechę **generatywności** (generowanie nowych danych)
   d. potrzebujemy próbkować rozkład w czasie inferencji (np. MAP)

Modele deskryptywne i generatywne

	Discriminative model	Generative model
Goal	Directly estimate $P(y\|x)$	Estimate $P(x\|y)$ to then deduce $P(y\|x)$
What's learned	Decision boundary	Probability distributions of the data
Illustration	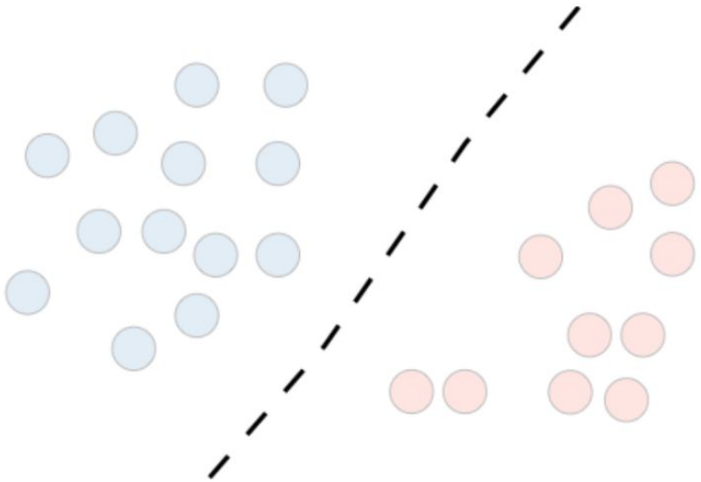	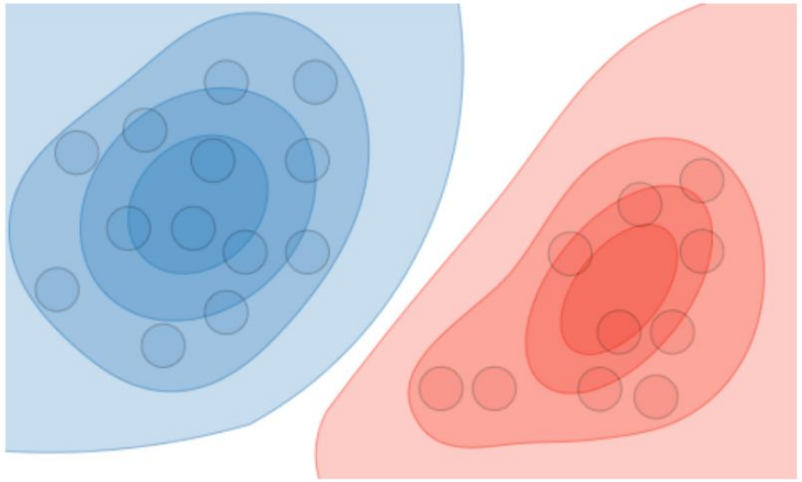
Examples	Regressions, SVMs	GDA, Naive Bayes

stanford.edu

Podsumowanie klasyfikatorów

	Typ	Liniowość	Interpretowalność	Skalowalność (duże *n*)	Klątwa wymiaru (duże *p*)	Hiperparametry	Parametry
kNN	deskryptywny	nie	słaba	słaba	odporny przy odpowiednio dobranej metryce	liczba sąsiadów, metryka, waga sąsiadów	brak
SVM	deskryptywny	tak i nie	możliwa / słaba	duża / słaba	odporny, przy odpowiednio dobranych jądrach	typ jądra, parametr *C*	wagi modelu
Regresja logistyczna	deskryptywny	tak	duża	duża	odporny, ale może wymagać regularyzacji	(ewentualnie regularyzacja)	wagi modelu
Naiwny Bayes	generatywny	tak i nie	możliwa	duża	odporny	rodzaj rozkładu $P(x \mid y)$	wartości $P(y)$, $P(x \mid y)$

Do zapamiętania

1. Regresja logistyczna (*logistic regression*)
2. Metoda największej wiarygodności (MLE)
3. Binarna entropia krzyżowa (*binary cross-entropy*)
4. Kategoryczna entropia krzyżowa (*categorical cross-entropy*)
5. Funkcja sigmoidalna i softmax
6. Twierdzenie Bayesa (*Bayes' theorem*)
7. Naiwny klasyfikator Bayesa (*naive Bayes classifier*)
8. Maksymalne szacowanie a posteriori (MAP)
9. Jądrowy estymator gęstości (KDE)
10. Elastyczny klasyfikator Bayesa
11. Modele deskryptywne i generatywne
12. Cechy klasyfikatorów (kNN, SVM, regresja logistyczna, naiwny klasyfikator Bayesa)