

Podstawy uczenia maszynowego

klasyfikacja niezbalansowana

ćwiczenia nr 5

Akademia Górniczo-Hutnicza
im. Stanisława Staszica w Krakowie
AGH University of Krakow

semestr letni 2025/2026

Paweł Szczerbiak

Czym się zajmiemy na ćwiczeniach?

Ćwiczenia 1: metody liniowe

Ćwiczenia 2: metody oparte na sąsiedztwie

Ćwiczenia 3: metody jądrowe

Ćwiczenia 4: metody probabilistyczne

Ćwiczenia 5: klasyfikacja niezbalansowana

Ćwiczenia 6: selekcja cech i redukcja wymiarowości

Ćwiczenia 7: klasteryzacja

Zagadnienia

1. Klasyfikacja niezbalansowana
2. Podpróbkiwanie (*undersampling*)
3. Nadpróbkiwanie (*oversampling*)
4. Rozszerzenie danych (*data augmentation*)
5. Dostrajanie progu (*threshold tuning*)
6. Uczenie uwzględniające koszty (*cost-sensitive learning*)
7. Metryki w klasyfikacji (niezbalansowanej)

Klasyfikacja niezbalansowana

Liczba przykładów w zbiorze treningowym dla poszczególnych klas **nie jest równa**

Sposoby rozwiązania tego problemu:

1. Inżynieria danych

- a. podpróbkiwanie (*undersampling*) – usuwamy przykłady z klasy większościowej
- b. nadpróbkiwanie (*oversampling*) – powielamy przykłady z klasy mniejszościowej
- c. rozszerzenie (*augmentation*) – modyfikujemy przykłady z klasy mniejszościowej


2. Modyfikacja modelu

- a. dostrajanie progu (*threshold tuning*) – obniżamy próg klasy pozytywnej z 50%
- b. uczenie uwzględniające koszty (*cost-sensitive learning*) – modyfikujemy funkcję kosztu

3. Połączenie powyższych technik


Podpróbkowanie losowe

Losowe usunięcie próbek klasy dominującej



Podpróbkiwanie z klastrowaniem


Usunięcie **mało ciekawych** próbek klasy dominującej, z dala od potencjalnej granicy decyzyjnej
np. *cluster centroids* (o klastrowaniu powiemy sobie innym razem)



Podpróbkiwanie z odszumianiem

Usunięcie **zaszumionych** próbek klasy dominującej blisko klasy mniejszościowej, które mogłyby "zepchnąć" granicę zbyt blisko niej np. *edited nearest neighbours*

1. Znajdź najbliższych sąsiadów dla klasy dominującej (domyślnie $k = 3$)
2. Zostaw tylko te punkty, dla których wszyscy sąsiedzi są z tej samej klasy



Podpróbkowanie – podsumowanie

- Używamy, gdy **mamy bardzo dużo danych** i rozsądną nierównowagę w danych
- Modyfikujemy tylko zbiór treningowy

Zalety


1. Pozwala na odsumienie zbioru danych i zmniejszenie braku balansu
2. Zmniejsza koszt obliczeniowy uczenia modelu
3. Prostota (w przypadku losowego podpróbkowania)

Wady

1. Może usunąć ważne próbki
2. Nie działa dla bardzo dużego braku balansu np. 1:99 (musielibyśmy zbyt drastycznie usunąć próbki z klasy pozytywnej)

Nadpróbkowanie losowe

Losowo powielamy próbki klasy mniejszościowej



Nadpróbkowanie ze SMOTE


Technika syntetycznego nadpróbkowania (*Synthetic Minority Oversampling TEchnique*)

1. Dla każdego punktu z klasy mniejszościowej znajdujemy jego k najbliższych sąsiadów z tej samej klasy (domyślnie $k = 5$)
2. Losujemy jednego z sąsiadów
3. Losujemy punkt na odcinku między punktem a sąsiadem – to jest nowy wygenerowany punkt
4. Powtarzamy punkty 2-3, dopóki nie uzyskamy pożądanej liczby punktów


Wady

1. Działa tylko z danymi ciągłymi, nie jest przeznaczony do generowania kategoriycznych danych syntetycznych
2. Wygenerowane dane są liniowo zależne, co może powodować odchylenia (*bias*) w wygenerowanych danych i generować nadmiernie dopasowany model (*overfitting*)

Nadpróbkowanie ze SMOTE




a) Class Imbalance




b) SMOTE

Nadpróbkowanie z bordeline-SMOTE

Używamy tylko punktów na granicy decyzyjnej tj. z dużą liczbą sąsiadów z klasy przeciwnej (oznaczonych jako DANGER). SVM-SMOTE używa w tym celu maszyn wektorów nośnych




a) Class Imbalance




b) Borderline-SMOTE

Nadpróbkowanie z ADASYN

Syntetyczne próbkowanie adaptacyjne (*ADaptive SYNthetic sampling*): dane syntetyczne są generowane w przestrzeniach zdominowanych przez przykłady z klasy przeciwnej




a) Class Imbalance



b) ADASYN



Nadpróbkowanie ze SMOTE – porównanie

przykład 1



Comparison of over-sampling methods
with a 3NN classifier

przykład 2



Nadpróbkowanie – podsumowanie

- Używamy, gdy **mamy mało danych**
- Modyfikujemy tylko zbiór treningowy

Zalety



1. Zachowujemy wszystkie dane oryginalne
2. Pomaga nauczyć się lepszej granicy decyzyjnej
3. Prostota (w przypadku losowego nadpróbkowania)

Wady

1. Może prowadzić do przeuczenia, jeśli widzi te same lub podobne przykłady wielokrotnie
2. Może propagować szum, jeśli dane mniejszościowe są zaszumione

Rozszerzenie danych (*data augmentation*)

Modyfikujemy przykłady z klasy mniejszościowej (popularne w *Vision ML* i NLP)



Inne techniki: przycinanie (*cropping*), usuwanie (*erasing*), dodawanie szumu (*noise injection*) etc.

Dostrajanie progu (*threshold tuning*)

- W klasyfikacji binarnej, model zwykle zwraca prawdopodobieństwo przynależności do klasy pozytywnej, np. $P(y=1|x)$, a potem klasyfikuje przykład jako:
 - 1 (pozytywna klasa), jeśli $p \geq 0.5$
 - 0 (negatywna klasa), jeśli $p < 0.5$
- Dostrajanie progu polega na zmianie progu z domyślnego 0.5 na inny, np. 0.3 lub 0.7, by lepiej dopasować się do konkretnego celu (np. większy czułość kosztem precyzji).

Zalety

1. Nie wymaga modyfikowania danych ani zmiany treningu modelu
2. Można dostroić pod konkretną metrykę (problem)

Wady

1. Działa tylko przy modelach probabilistycznych
2. Nie rozwiązuje problemu nierównowagi sam w sobie

Uczenie uwzględniające koszty – ważenie klas

Zmieniamy algorytm, aby włączyć do niego wagi klas (*class weights*) i zwrócić większą uwagę na klasy mniejszościowe:

$$\text{class_weight}(y) = \frac{n}{K * |\text{class}(y)|}$$

n – liczba próbek

K – liczba klas

$|\text{class}(y)|$ – liczba przykładów dla klasy y

- Algorytmy z funkcją kosztu


$$L(\hat{y}, y) = \sum_{i=1}^n \text{class_weight}(y_i) * \text{loss}(\hat{y}_i, y_i)$$

regresja liniowa i logistyczna, liniowy SVM,
drzewa decyzyjne, lasy losowe, sieci neuronowe

- Kernel SVM: ważymy parametr C za pomocą wag klas (bez ważenia granica decyzyjna jest przesunięta dalej od granicy decyzyjnej)
- kNN: ważymy głosy (klasyfikacja) albo używamy średniej ważonej (regresja)
- Naiwny klasyfikator Bayesa: działa automatycznie dla klas niezbalansowanych dzięki $P(y)$

Uczenie uwzględniające koszty – fokalna funkcja straty

Zmieniamy funkcję straty, aby zwracała większą uwagę na klasy mniejszościowe



Uczenie uwzględniające koszty – podsumowanie

Zalety

1. Najprostsze i najszybsze rozwiązanie:

w scikit-learn używamy: `class_weight="balanced"`

2. działa dla praktycznie wszystkich algorytmów (też dla sieci neuronowych)

Wady

1. Zbyt wysokie wagi mogą spowodować przeuczenie klasy mniejszościowej
2. nie wystarcza przy bardzo dużej nierównowadze klas, trzeba łączyć z innymi modyfikacjami

Metryki w klasyfikacji – podstawowe metryki

$$\text{precision} = \frac{TP}{TP+FP} \quad (\text{precyzja})$$

$$\text{recall} = \frac{TP}{TP+FN} = \frac{TP}{P} = TPR \quad (\text{sensitivity}) \quad (\text{czułość})$$

$$\text{specificity} = \frac{TN}{TN+FP} = \frac{TN}{N} = TNR \quad (\text{specyficzność})$$

$$\text{false alarm} = \frac{FP}{TN+FP} = FPR = \frac{FP}{N} = 1 - TNR \quad \text{błąd I rodzaju}$$

$$\text{miss rate} = \frac{FN}{TP+FN} = FNR = \frac{FN}{P} = 1 - \text{recall} \quad \text{błąd II rodzaju}$$

$$\text{balanced accuracy} = \frac{TPR+TNR}{2} = 1 - \frac{\text{false alarm} + \text{miss rate}}{2} \quad (\text{dokładność zbalansowana})$$

$$\text{f1-score} = 2 \frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}} \quad (\text{współczynnik f1})$$

$$\text{MCC} = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP+FP)(TP+FN)(TN+FP)(TN+FN)}} \quad (\text{współczynnik korelacji Matthews, fi})$$

		ACTUAL VALUES	
		POSITIVE	NEGATIVE
PREDICTED VALUES	POSITIVE	TP	FP
	NEGATIVE	FN	TN

Metryki w klasyfikacji – podstawowe metryki

$$\text{precision} = \frac{TP}{TP+FP} \quad (\text{precyzja})$$

$$\text{recall} = \frac{TP}{TP+FN} = \frac{TP}{P} = TPR \quad (\text{sensitivity}) \quad (\text{czułość})$$

$$\text{specificity} = \frac{TN}{TN+FP} = \frac{TN}{N} = TNR \quad (\text{specyficzność})$$

$$\text{false alarm} = \frac{FP}{TN+FP} = FPR = \frac{FP}{N} = 1 - TNR \quad \text{błąd I rodzaju}$$

$$\text{miss rate} = \frac{FN}{TP+FN} = FNR = \frac{FN}{P} = 1 - \text{recall} \quad \text{błąd II rodzaju}$$

$$\text{balanced accuracy} = \frac{TPR+TNR}{2} = 1 - \frac{\text{false alarm} + \text{miss rate}}{2} \quad (\text{dokładność zbalansowana})$$

$$\text{f1-score} = 2 \frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}} \quad (\text{współczynnik f1})$$

$$\text{MCC} = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP+FP)(TP+FN)(TN+FP)(TN+FN)}} \quad (\text{współczynnik korelacji Matthews'a, fi})$$

		ACTUAL VALUES	
		POSITIVE	NEGATIVE
PREDICTED VALUES	POSITIVE	TP	FP
	NEGATIVE	FN	TN

Metryki w klasyfikacji – podstawowe metryki

balanced accuracy

- mierzy skuteczność obu klas równomiernie
- dobry jako główna metryka
- nie rozróżnia źródła błędu (oba są tak samo traktowane)

f1-score

- koncentruje się na jakości wykrywania klasy pozytywnej
- dobry, gdy interesuje nas tylko klasa pozytywna (wykrywanie rzadkich zdarzeń)
- dwa modele mogą mieć ten sam f1-score, ale zupełnie różną precyzję i czułość

MCC

- daje pojedynczą, spójną miarę uwzględniającą cały kontekst macierzy pomyłek
- dobry jako główna metryka
- jest mniej intuicyjny


Metryki w klasyfikacji – AUROC

Area Under Receiver Operating Characteristic

- Pole powierzchni pod krzywą charakterystyki operacyjnej odbiornika
- Pokazuje balans między błędem I i II rodzaju
- Klasyfikator losowy ma AUROC = 0.5
- Działa dobrze dla średnio niezbalansowanych klas
- Nie działa dobrze dla ekstremalnej nierównowagi:

$$\text{false alarm} = \frac{FP}{TN+FP} = FPR$$



gdy TN jest bardzo duże, AUROC również będzie względnie duże, co może być mylące, jeśli interesuje nas głównie klasa pozytywna



Metryki w klasyfikacji – AUPRC

Area Under Precision-Recall Curve


- Pole powierzchni pod krzywą precyzji-czułości
- Skupia się na klasie pozytywnej (precyzja)
- Klasyfikator losowy ma AUPRC równy ułamkowi klasy pozytywnej
- Działa dobrze również dla wysokiej nierównowagi klas (nieoczywiste i powinno być raportowane)
- Kontroluje *precision-recall tradeoff*
- Lepiej odzwierciedla realną jakość modelu niż AUROC, gdy klasa pozytywna jest rzadka



Metryki w klasyfikacji – więcej niż 2 klasy

Multiclass Classification vs multilabel classification

Multiclass Classification




Classes

(pick one class)

- ☒ Dog
- ☐ Cat
- ☐ Horse
- ☐ Mouse

Multilabel Classification



Classes

(pick all the labels present in the image)

- ☒ Dog
- ☒ Cat
- ☐ Horse
- ☐ Mouse

Metryki w klasyfikacji – więcej niż 2 klasy

Sposoby uśredniania (agregacji)

1. *macro* – liczy metrykę osobno dla każdej klasy, a potem uśrednia równo
2. *micro* – liczy TP/FP/FN globalnie (sumuje po klasach), a potem z nich wylicza jedną metrykę
3. *weighted* – jak *macro*, ale uśrednia, ważąc liczbą przykładów w każdej klasie
4. *per-class* – raportuje osobno każdą klasę (dobry sposób na dokładny przegląd)
5. *samples* – średnia z metryk liczonych osobno dla każdej próbki (tylko *multi-label*)

Metryki

- dokładność zbalansowana – używamy *macro* uśrednienia
- współczynnik f1 – obsługuje wszystkie sposoby agregacji
- MCC – naturalne uogólnienie na wiele klas ([link](#))
- AUROC – *one-vs-rest* (OvR) i agregacja
- AUPRC – *one-vs-rest* (OvR) i agregacja

Do zapamiętania

1. Klasyfikacja niezbalansowana
 - a. definicja
 - b. jak sobie z nią radzić
2. Podpróbkiwanie (*undersampling*)
 - a. losowe
 - b. z klastrowaniem (*cluster centroids*)
 - c. z odszumianiem (*edited nearest neighbours*)
3. Nadpróbkiwanie (*oversampling*)
 - a. losowe
 - b. SMOTE i jego modyfikacje
4. Rozszerzenie danych (*data augmentation*)
5. Dostrajanie progu (*threshold tuning*)
6. Uczenie uwzględniające koszty (*cost-sensitive learning*)
 - a. ważenie klas
 - b. fokalna funkcja straty
7. Metryki w klasyfikacji
 - a. dokładność zbalansowana
 - b. współczynnik f1
 - c. MCC
 - d. AUROC
 - e. AUPRC
 - f. więcej niż 2 klasy