

Podstawy uczenia maszynowego

selekcja cech i redukcja wymiarowości

ćwiczenia nr 6

Akademia Górniczo-Hutnicza
im. Stanisława Staszica w Krakowie
AGH University of Krakow

semestr letni 2025/2026

Paweł Szczerbiak

Czym się zajmiemy na ćwiczeniach?

Ćwiczenia 1: metody liniowe

Ćwiczenia 2: metody oparte na sąsiedztwie

Ćwiczenia 3: metody jądrowe

Ćwiczenia 4: metody probabilistyczne

Ćwiczenia 5: klasyfikacja niezbalansowana

Ćwiczenia 6: selekcja cech i redukcja wymiarowości

Ćwiczenia 7: klasteryzacja

Zagadnienia

1. Selekcja cech
2. Metody selekcji cech:
 - a. filtracyjne
 - b. opakowujące
 - c. wbudowane
3. Redukcja wymiarowości
4. Metody liniowe
 - a. *Rozkład według wartości osobliwych (SVD)*
 - b. *Analiza głównych składowych (PCA)*
5. Metody nieliniowe

Selekcja cech

Chcemy wybrać tylko te zmienne, **które jak najlepiej wyjaśniają** dane zjawisko

Zakłócenia mogą pochodzić m.in. od:

- szumu
- punktów odstających
- nadmiarowości informacji
- braku związku ze zmiennymi wyjaśnianymi

Zaleta: interpretowalność (*feature importance*)

Wada: nie przekształca cech, nie rozważa złożonych kombinacji

Selekcja cech

Szczególnie ważna dla modeli, które używają cech wprost, bez przekształceń np.:

- modele liniowe (nadmiarowość i szum)
- kNN (zbędne cechy) **bardzo istotne!**
- Naiwny klasyfikator Bayesa (zbędne cechy)
- MLP (koszt obliczeniowy)

Zastosowanie:

- genetyka (asocjacje gen-choroba)
- analityka biznesowa / marketing (dopasowanie pod cechy klienta)
- finanse (modele scoringowe)
- NLP (istotne są słowa kluczowe)

Selekcja cech – metody

1. **Filtracyjne** (*filter methods*):

- a. oceniają cechy niezależnie od modelu, używając statystyk
- b. są szybkie i nie zależą od konkretnego algorytmu uczącego

2. **Opakowujące** (*wrapper methods*):

- a. używają konkretnego modelu, by ocenić jakość różnych podzbiorów cech
- b. szukają najlepszej kombinacji, opierając się na wyniki modelu

3. **Wbudowane** (*embedded methods*):

- a. selekcja cech odbywa się w trakcie trenowania modelu
- b. model sam „uczy się”, które cechy są ważne

Selekcja cech – metody filtracyjne

Przykłady:

- Odrzucenie cech o małej wariancji (*variance threshold*)
- Korelacja między cechami (np. Pearsona, Spearmana) **omawialiśmy!**
- Informacja wzajemna cecha-zmienna wyjaśniana (*mutual Information*)

$$I(X; Y) = \int_{y \in Y} \int_{x \in X} P(x, y) \log \left(\frac{P(x, y)}{P(x)P(y)} \right) dx dy$$

- Istotność statystyczna cecha-zmienna wyjaśniająca:
 - ANOVA (dla danych liczbowych, klasyfikacja)
 - Chi-kwadrat (dla danych kategorycznych)

Zalety: szybkie, skalowalne, niezależne od modelu

Wady: ignorują zależności między cechami, niedopasowane do konkretnego modelu

Selekcja cech – metody opakowujące

Przykłady:

- Modele ML:
 - RFE (*Recursive Feature Elimination*) – rekurencyjne usuwanie najmniej istotnych cech
- Testy statystyczne:
 - *Forward selection* – dodajemy jedną cechę na raz
 - *Backward elimination* – zaczynamy od wszystkich, usuwamy jedną na raz
- Algorytmy genetyczne (*genetic algorithms*)

Zalety: lepsza optymalizacja pod konkretny model

Wady: bardzo kosztowne obliczeniowo, mogą przeuczać (*overfitting*)

Selekcja cech – metody wbudowane

Przykłady:

- Regresja Lasso (*Lasso regression*) – przypisuje zerowe współczynniki nieistotnym cechom
- Regresja grzbietowa (*ridge regression*) – zmniejsza wpływ mniej istotnych cech
- Regresja ElasticNet – łączy L1 i L2
- Drzewa decyzyjne i lasy losowe – mierzą istotność cech (np. *Gini importance*)
- XGBoost / LightGBM – mają wbudowane metryki ważności cech (*gain, cover, frequency*)

Zalety: często najlepszy kompromis między jakością a kosztem obliczeniowym,
dostosowane pod model

Wady: zależne od konkretnego modelu, czasem trudniejsze do interpretacji

Redukcja wymiarowości

Rzutujemy cechy (*feature projection*) na nową przestrzeń o mniejszej liczbie wymiarów

- tworzy nowe, złożone cechy
- redukcja do 2-3 wymiarów pozwala zobrazować wysokowymiarowe dane
- może być stosowana np. do analiza klastrow czy zależności w danych

Metody:

- liniowe – rzutowanie to przekształcenie liniowe, typowo mnożenie macierzowe
- nieliniowe – rzutowanie to funkcja nieliniowa

Zaleta: rozważa złożone przekształcenia całej przestrzeni cech

Wada: metody nieliniowe są często nieinterpretowalne, a liniowe – zbyt uproszczone

Redukcja wymiarowości – metody liniowe (SVD)

Rozkład według wartości osobliwych (*Singular value decomposition*)

- **Uogólnienie rozkładu macierzy** kwadratowej na wektory i wartości własne
- Rozważamy macierze prostokątne $n \times d$ (zarówno rzeczywiste jak i zespolone)
- Znajdujemy wektory cech po liniowej transformacji
- Geometryczne odpowiadają one obrotowi, skalowaniu i kolejnemu obrotowi oryginalnych cech

$$\begin{matrix} [n \times d] & [n \times n] & [d \times d] \\ M = U \Sigma V^* \\ [n \times d] \end{matrix}$$

$$U^*U = V^*V = I_r$$

$$M = \sum_{i=1}^r \sigma_i u_i v_i^*$$

kompresja
(r to rząd M)

rozkład


$$[d \times d] \quad M^*M = V \Sigma^* U^* U \Sigma V^* = V (\Sigma^* \Sigma) V^*$$

V to “prawe” wektory własne macierzy M^*M

$$[n \times n] \quad MM^* = U \Sigma V^* V \Sigma^* U^* = U (\Sigma \Sigma^*) U^*$$



U to “lewe” wektory własne macierzy MM^*

Redukcja wymiarowości – metody liniowe (SVD)



$$M = U \cdot \Sigma \cdot V^*$$

kompresja



selekcja cech

$$\tilde{M} = M\tilde{V}$$

$$\tilde{d} \leq r \leq d$$

Redukcja wymiarowości – metody liniowe (PCA)

Analiza głównych składowych (*Principal component analysis*)

- Rzutowanie (redukcja) macierzy na nowy układ współrzędnych
- W układzie tym cechy mają największą wyjaśnialność wariancji w danych
- Matematycznie jest to **diagonalizacja macierzy kowariancji**
- **PCA zakłada, że cechy są wycentrowane** (zob. [kowariancja próby](#))
- jeżeli nasze cechy mają różną skalę, to dodatkowo je standaryzujemy
- **Wada:** nie działa dla cech rzadkich: centrowanie niszczy rzadkość
- **Zaleta (względem SVD):** interpretacja statystyczna
- Zastosowanie: eksploracja danych, wizualizacja, redukcja wymiarowości – nie powinniśmy używać tej techniki do wyciągania wniosków (zob. [ten](#) artykuł)!

Redukcja wymiarowości – metody liniowe (PCA)

- Definicja:

$$\text{cov}(M) = \frac{M^T M}{n-1} = V S V^T \longrightarrow S = \frac{\Sigma^2}{n-1}$$

- związek między PCA a SVD (zob. [link](#)):

$$\frac{M^T M}{n-1} \stackrel{\text{SVD}}{=} \frac{(U \Sigma V^T)^T (U \Sigma V^T)}{n-1} = \frac{V \Sigma U^T U \Sigma V^T}{n-1} = V \frac{\Sigma^2}{n-1} V^T$$



- j-ta główna składowa (*j'th principal component*):

$$\tilde{M}_{.j} = (M V)_{.j}$$

- fundamentalne twierdzenie analizy czynnikowej (*factor analysis*):

$$\text{cov}(M) = L L^T \implies L = V S^{\frac{1}{2}} \quad \text{loadings (zob. [link](#))}$$

Redukcja wymiarowości – metody liniowe (PCA)



Redukcja wymiarowości – metody nieliniowe (t-SNE)

t-distributed Stochastic Neighbor Embedding

- Popularna metoda wizualizacji wysokowymiarowych danych w 2D lub 3D
- Działa dobrze dla małych i średnich zbiorów danych
- Modeluje podobieństwa w przestrzeni wysokowymiarowej jako prawdopodobieństwa (jądra Gaussowskie)
- W przestrzeni niskowymiarowej używa rozkładu t-Studenta (z 1 stopniem swobody) dla rozkładu odległości
- Minimalizuje dywergencję Kullbacka-Leiblera (KL) między rozkładami podobieństwa w przestrzeni wysokowymiarowej i niskowymiarowej

Zalety: zachowuje głównie lokalną strukturę danych, zawiera tylko jeden hiperparametr

Wady: duża złożoność obliczeniowa, problemy z utrzymaniem globalnej struktury

Redukcja wymiarowości – metody nieliniowe (UMAP)

Uniform Manifold Approximation and Projection

- Bardziej nowoczesna, szybsza metoda redukcji wymiarowości
- Buduje graf kNN i estymuje miarę podobieństwa w przestrzeni wysokowymiarowej
- Optymalizuje reprezentację niskowymiarową, minimalizując różnicę między grafami wysokowymiarowymi i niskowymiarowymi za pomocą entropii krzyżowej

Zalety: zachowuje zarówno lokalną, jak i globalną strukturę danych lepiej niż t-SNE,
skalowalna do dużych zbiorów danych

Wady: zawiera trzy hiperparametry

Redukcja wymiarowości – metody nieliniowe (TriMAP)

Triplet-based Manifold Approximation and Projection

- Zaprojektowana, by lepiej zachować globalne relacje danych niż t-SNE i UMAP
- Selekcjonuje trójki (i,j,k) , gdzie i jest bliższy j , niż k w przestrzeni wysokowymiarowej
- Minimalizuje błędy związane z zachowaniem tej relacji
- Optymalizacja oparta jest na funkcjach strat nad zbiorami trójek

Zalety: zachowuje zarówno lokalną, jak i globalną strukturę danych lepiej niż t-SNE

Wady: zawiera aż cztery hiperparametry i wiele parametrów, średnio szybka

Redukcja wymiarowości – metody nieliniowe (PaCMAP)

Pairwise Controlled Manifold Approximation Projection

- Metoda nowsza, konkurencyjna dla UMAP i t-SNE
- Buduje zestaw par punktów: bliskich sąsiadów, średnio odległych punktów i dalekich punktów
- Minimalizuje funkcję straty, która jednocześnie chce zbliżyć bliskie pary (lokalna struktura) oraz odpowiednio oddalić średnio odległe i dalsze pary (globalna struktura)
- Funkcja straty jest sumą ważoną błędów odległości między tymi grupami

Zalety: zachowuje zarówno lokalną, jak i globalną strukturę danych lepiej niż t-SNE


Wady: zawiera trzy hiperparametry

Redukcja wymiarowości – metody nieliniowe

Metoda	Zachowanie lokalnej struktury	Zachowanie globalnej struktury	Szybkość	Skala danych	Hiperparametry
t-SNE	Bardzo dobre	Słabe	Wolna	Małe / średnie	1
UMAP	Bardzo dobre	Dobre	Szybka	Duże	3
TriMAP	Dobre	Bardzo dobre	Średnia	Duże	4
PaCMAP	Bardzo dobre	Dobre / bardzo dobre	Szybka	Duże	3

Redukcja wymiarowości – metody nieliniowe

t-SNE(perplexity=10)



UMAP(n_neighbors=10)



TriMAP(n_inliers=8)



t-SNE(perplexity=20)



UMAP(n_neighbors=20)



TriMAP(n_inliers=10)



t-SNE(perplexity=40)



UMAP(n_neighbors=40)



TriMAP(n_inliers=15)




PaCMAP




PaCMAP(default)




Original Mammoth



t-SNE(perplexity=10)




t-SNE(perplexity=125)



LargeVis(perplexity=125)




UMAP(NN=10)



TriMAP(NN=10)



t-SNE(perplexity=20)



t-SNE(perplexity=250)



LargeVis(perplexity=250)



UMAP(NN=20)



TriMAP(NN=20)



t-SNE(perplexity=40)



t-SNE(perplexity=500)



LargeVis(perplexity=500)



UMAP(NN=40)



TriMAP(NN=40)



Do zapamiętania

1. Selekcja wymiarowości (definicja)
2. Metody selekcji cech:
 - a. filtracyjne
 - b. opakowujące
 - c. wbudowane
3. Redukcja wymiarowości
4. Metody liniowe
 - a. *Rozkład według wartości osobliwych (SVD)*
 - b. *Analiza głównych składowych (PCA)*
 - c. Związek między SVD a PCA
5. Metody nieliniowe:
 - a. t-SNE
 - b. UMAP
 - c. triMAP
 - d. PaCMAP